3. Характеризация на регулярните езици. Теорема на Майхил-Нероуд

Тема: 3. Характеризация на регулярните езици. Теорема на Майхил-Нероуд

Регулярните езици са един от основните класове формални езици. Те са езиците, които могат да бъдат описани чрез регулярни изрази, разпознати от крайни автомати или получени чрез регулярни операции. Основната идея е, че за разпознаването на такъв език е достатъчна крайна памет. Крайният автомат не помни цялата прочетена дума, а само едно от краен брой състояния, което обобщава цялата информация, нужна за решението дали думата принадлежи на езика.

Нека () е крайна азбука. Език над () е всяко множество (L ^), където (^) е множеството на всички крайни думи над азбуката (), включително празната дума (). Един език се нарича регулярен, ако може да бъде зададен чрез регулярен израз, тоест чрез крайно прилагане на операциите обединение, конкатенация и итерация на Клини върху елементарните езици (), ({}) и ({a}) за (a).

Детерминиран краен автомат е петорка

$$A = (Q, \Sigma, \delta, q_0, F),$$

където (Q) е крайно множество от състояния, () е входна азбука, (:QQ) е функция на преходите, (q_0Q) е начално състояние, а (FQ) е множеството от финални състояния. Ако функцията () е дефинирана за всяка двойка от състояние и буква, автоматът се нарича тотален. Функцията () се разширява по естествен начин до функция

$$\delta^{\cdot} Q \times \Sigma^{\rightarrow} Q,$$

като (^(q,)=q), а ($^{(q,wa)=}$(q,w),a)). Това означава, че (^(q,w)) е състоянието, в което автоматът попада, ако започне от състояние (q) и прочете думата (w).

Езикът, разпознат от автомата (A), се дефинира като

$$L(A) = w \in \Sigma^* \mid \delta^*(q_0, w) \in F.$$

Такъв език се нарича автоматен език. Тоест една дума принадлежи на езика на автомата точно когато след прочитането ѝ от началното състояние автоматът завърши във финално състояние.

Теоремата на Клини установява фундаментална връзка между регулярните изрази и крайните автомати. Тя гласи, че един език е регулярен тогава и само тогава, когато се разпознава от краен автомат. С други думи, класът на езиците, описуеми с

регулярни изрази, съвпада с класа на автоматните езици. Тази теорема позволява да използваме регулярни изрази, недетерминирани автомати и детерминирани крайни автомати като еквивалентни модели за един и същ клас езици.

За по-дълбока характеризация на регулярните езици се въвежда релацията на Майхил-Нероуд. Нека (L^) е език. За две думи (u,v^) казваме, че (u) и (v) са еквивалентни по отношение на (L), и пишем

$$u \equiv_L v,$$

ако за всяка дума (x^*) е изпълнено

$$ux \in L \Leftrightarrow vx \in L.$$

Тази релация означава, че думите (u) и (v) не могат да бъдат различени от езика (L) чрез добавяне на каквото и да е продължение (x). Ако всяко възможно продължение води или и двете думи в езика, или и двете извън езика, тогава (u) и (v) са еквивалентни. Интуитивно, релацията групира думите според това какво значение имат за бъдещото разпознаване на езика.

Първо се доказва, че (_L) е релация на еквивалентност. Трябва да се проверят трите свойства: рефлексивност, симетричност и транзитивност. Рефлексивността е непосредствена, защото за всяка дума (u) и всяко продължение (x) твърдението (uxL) е еквивалентно само на себе си. Следователно (u_L u). Симетричността също е ясна. Ако (u_L v), тогава за всяко (x) имаме (uxL) тогава и само тогава, когато (vxL). Но логическата еквивалентност е симетрична, следователно (vxL) тогава и само тогава, когато (uxL), тоест (v_L u). За транзитивността нека (u_L v) и (v_L z). Тогава за всяко продължение (x) имаме (uxL) тогава и само тогава, когато (vxL), а също (vxL) тогава и само тогава, когато (zxL). Следователно (uxL) тогава и само тогава, когато (zxL), което означава (u_L z). Така (_L) е релация на еквивалентност.

След това се доказва, че релацията (_L) е дясно инвариантна. Дясна инвариантност означава, че ако (u_L v), то за всяка дума (y^*) е изпълнено

$$uy \equiv_L vy.$$

Доказателството следва директно от дефиницията. Нека (u_L v) и нека (y) е произволна дума. За да докажем, че (uy_L vy), трябва да покажем, че за всяко продължение (x) е вярно

$$uyx \in L \Leftrightarrow vyx \in L.$$

Но думата (yx) е просто едно възможно продължение на (u) и (v). Понеже (u_L v), за всяка дума (z) имаме (uzL) тогава и само тогава, когато (vzL). Полагаме (z=yx) и получаваме точно (uyxL) тогава и само тогава, когато (vyxL). Следователно (uy_L vy), тоест релацията е дясно инвариантна.

Индекс на релацията (_L) се нарича броят на нейните класове на еквивалентност. Ако индексът е краен, това означава, че всички думи над азбуката могат да бъдат разделени на краен брой групи, като думите в една и съща група са неразличими по отношение на езика (L).

Следващата важна стъпка е да се докаже, че ако релацията (_L) има краен индекс (n), тогава езикът (L) се разпознава от тотален детерминиран краен автомат с (n) състояния. Нека класовете на еквивалентност на (_L) са

$$[w_1], [w_2], ..., [w_n].$$

Построяваме автомат, чиито състояния са точно тези класове на еквивалентност. Началното състояние е класът на празната дума ([]). За буква (a) дефинираме прехода от клас ([w]) с буква (a) като

$$\delta([w], a) = [wa].$$

Тази дефиниция е коректна, защото релацията е дясно инвариантна. Ако изберем друг представител (w') на същия клас, то (w_L w'), следователно (wa_L w'a), и значи ([wa]=[w'a]). Затова преходът не зависи от избрания представител.

Финалните състояния са класовете ([w]), за които (wL). Това също е коректно, защото ако (w_L w'), тогава вземаме продължение (x=) и получаваме (wL) тогава и само тогава, когато (w'L). Следователно или всички думи в даден клас принадлежат на (L), или нито една не принадлежи на (L).

Полученият автомат е краен, защото има (n) състояния, и е тотален, защото за всеки клас ([w]) и всяка буква (a) преходът ([wa]) е дефиниран. Остава да се провери, че той разпознава точно езика (L). След прочитане на дума (w) от началното състояние ([]), автоматът ще бъде в състояние ([w]). Това се доказва по индукция по дължината на (w). За празната дума е вярно, защото началното състояние е ([]). Ако е вярно за (w), то след прочитане на буква (a) автоматът преминава от ([w]) в ([wa]). Следователно за всяка дума (w) състоянието след прочитането ѝ е ([w]). Думата се приема точно когато ([w]) е финален клас, тоест точно когато (wL). Следователно построеният автомат разпознава (L).

Обратната посока гласи, че ако езикът (L) се разпознава от тотален детерминиран краен автомат с (n) състояния, тогава индексът на релацията (_L) е не повече от (n). Нека

$$A = (Q, \Sigma, \delta, q_0, F)$$

е такъв автомат и (|Q|=n). За всяка дума (w) автоматът попада в някакво състояние (^(q_0,w)). Ако две думи (u) и (v) водят автомата до едно и също състояние, тоест

$$\delta^(q_0, u) = \delta^*(q_0, v),$$

тогава те са еквивалентни по Майхил-Нероуд. Наистина, за всяко продължение (x), след прочитане на (ux) автоматът ще бъде в същото състояние, както след прочитане на (vx), защото след (u) и след (v) той започва от едно и също състояние и после чете една и съща дума (x). Следователно или и двете думи (ux) и (vx) се приемат, или и двете се отхвърлят. Значи (uxL) тогава и само тогава, когато (vxL), тоест (u_L v).

Това показва, че всеки клас на еквивалентност по (_L) е обединение, съвместимо със състоянията на автомата, и по-точно различими думи не могат да водят до едно и също състояние. Следователно броят на класовете на (_L) не може да е по-голям от броя на състоянията на автомата. Значи индексът на (_L) е най-много (n).

От тези две посоки следва теоремата на Майхил-Нероуд. Тя гласи, че един език (L^*) е регулярен тогава и само тогава, когато релацията (_L) има краен индекс.

Доказателството е следното. Ако (_L) има краен индекс, тогава, както вече доказахме, можем да построим тотален детерминиран краен автомат, чиито състояния са класовете на еквивалентност на (_L), и този автомат разпознава (L). Следователно (L) е автоматен език, а по теоремата на Клини е регулярен.

Обратно, ако (L) е регулярен, тогава по теоремата на Клини (L) се разпознава от краен автомат. Можем да вземем тотален детерминиран краен автомат за (L). Ако този автомат има (n) състояния, тогава, както доказахме, индексът на (_L) е не повече от (n). Следователно индексът е краен.

Така релацията на Майхил-Нероуд дава точна характеристика на регулярните езици. Тя казва, че един език е регулярен точно когато има само краен брой различни „остатъчни поведения“ спрямо продълженията на думите. Ако след прочитане на произволна дума са възможни само краен брой различни състояния на бъдещо поведение, езикът може да бъде разпознат от краен автомат. Ако обаче съществуват безкрайно много думи, които могат да бъдат различени чрез подходящи продължения, тогава езикът не може да бъде регулярен.

Тази теорема има и важно практическо приложение. За построяване на минимален тотален детерминиран краен автомат състоянията трябва да съответстват на класовете на еквивалентност по релацията на Майхил-Нероуд. Две думи водят до едно и също състояние в минималния автомат точно когато са неразличими спрямо езика, тоест когато принадлежат на един и същ клас. Затова броят на състоянията в минималния автомат е точно индексът на релацията (_L).

Теоремата се използва и за доказване, че даден език не е регулярен. За да се докаже нерегулярност, достатъчно е да се намери безкрайно множество от думи, които са по двойки различими спрямо езика. Това означава, че за всеки две различни думи от това множество трябва да съществува продължение, което поставя едната дума в езика, а другата извън езика. Ако има безкрайно много такива различими думи, релацията (_L) има безкраен индекс и по теоремата на Майхил-Нероуд езикът не е регулярен.

Основната идея на цялата тема е следната. Регулярният език е език, който може да бъде разпознат с краен брой състояния. Релацията на Майхил-Нероуд формализира кои думи са неразличими от гледна точка на бъдещите продължения. Ако има само краен брой такива класове на неразличимост, те могат да се използват като състояния на краен автомат. Ако езикът се разпознава от краен автомат, тогава автоматът сам налага краен брой възможни поведения, следователно релацията има краен индекс. Така крайността на индекса на релацията е точно условието за регулярност.