4. Лема за разрастването за контекстносвободни езици. Незатвореност относно сечение и допълнение

Тема: 4. Лема за разрастването за контекстносвободни езици. Незатвореност относно сечение и допълнение

Контекстносвободните, или безконтекстните, езици са клас формални езици, които се пораждат от контекстносвободни граматики. Те са по-общи от регулярните езици и позволяват описване на структури, при които има вложеност или зависимост между части на думата, например балансирани скоби или еднакъв брой символи от два вида. Основната идея е, че правилата в граматиката заменят един нетерминален символ независимо от контекста, в който той се намира.

Контекстносвободна граматика е четворка

$$G = (V, \Sigma, R, S),$$

където (V) е крайно множество от нетерминални символи, () е крайно множество от терминални символи, като (V=), (R) е крайно множество от правила, а (SV) е начален символ. Всяко правило има вида

$$A \to \alpha,$$

където (AV), а ((V)^*). Граматиката се нарича контекстносвободна, защото нетерминалът (A) може да бъде заменен с думата () независимо от символите около него.

Извод в контекстносвободна граматика е последователност от прилагания на правила. Ако имаме дума (A) и правило (A), можем да заменим (A) с () и да получим

$$\beta A \gamma \Rightarrow \beta \alpha \gamma.$$

Ако чрез краен брой стъпки от думата (_1) се получава думата (_2), пишем

$$\omega_1 \Rightarrow_2^{\omega} .$$

Езикът, породен от граматиката (G), е множеството от всички терминални думи, които могат да бъдат изведени от началния символ:

$$L(G) = w \in \Sigma^{|} S \Rightarrow^{*} w.$$

Език се нарича контекстносвободен, ако съществува контекстносвободна граматика, която го поражда.

Дърво на извод в контекстносвободна граматика е дървовидно представяне на извод. Коренът на дървото е началният символ (S). Всеки вътрешен връх е нетерминален символ. Ако за нетерминал (A) е приложено правило (AX_1X_2X_k), тогава върхът, означен с (A), има деца, означени съответно с (X_1,X_2,,X_k). Листата на дървото, прочетени отляво надясно, образуват получената дума. Дървото на извод показва не само, че дадена дума се извежда, но и каква е нейната синтактична структура.

Контекстносвободните езици са затворени относно регулярните операции обединение, конкатенация и итерация на Клини. Тук се дават конструкциите, без да е необходимо пълно доказателство. Ако (L_1) и (L_2) са контекстносвободни езици с граматики с начални символи (S_1) и (S_2), за обединението (L_1L_2) въвеждаме нов начален символ (S) и правила

$$S \to S_1 \mid S_2.$$

Така новата граматика избира дали да породи дума от първия или от втория език. За конкатенацията (L_1L_2) въвеждаме ново правило

$$S \to S_1 S_2.$$

Така първо се поражда дума от (L_1), а след това дума от (L_2). За итерацията (L_1^*) въвеждаме нов начален символ (S) и правила

$$S \to S_1 S \mid \varepsilon.$$

Това позволява да се породят нула, една или повече последователни думи от (L_1). Следователно контекстносвободните езици са затворени относно трите регулярни операции.

Основният инструмент за доказване, че даден език не е контекстносвободен, е лемата за разрастването за контекстносвободни езици. Тя дава необходимо условие за контекстносвободност. Ако един език е контекстносвободен, то всяка достатъчно дълга дума от него може да бъде разделена на пет части, така че две от тези части да могат да се повтарят едновременно произволен брой пъти и резултатът отново да остава в езика.

Лемата за разрастването гласи следното. Ако (L) е контекстносвободен език, тогава съществува естествено число (p), наречено константа на разрастване, такова че всяка дума (zL) с (|z|p) може да се представи във вида

$$z = uvwxy,$$

като са изпълнени условията

$$|vwx| \leq p,$$

$$|vx| > 0,$$

и за всяко (i) е вярно, че

$$uv^i wx^i y \in L.$$

Смисълът на това твърдение е, че в достатъчно дълга дума, породена от контекстносвободна граматика, в дървото на извод трябва да има повторение на нетерминален символ по някой път от корена към листо. Това повторение позволява част от извода да бъде повторена или премахната. Понеже граматиката е контекстносвободна, същият нетерминал може да бъде заменян по един и същ начин независимо от контекста, в който се намира.

Доказателството на лемата използва дърво на извод. Нека (L) е контекстносвободен език. Можем да разглеждаме граматика за (L), приведена в нормална форма на Чомски, тоест такава, в която правилата са от вида (ABC) или (Aa), с евентуално специално правило за празната дума. Нека броят на нетерминалите в граматиката е (m). Избираме константа (p=2^m). Ако дума (zL) има дължина поне (p), то всяко дърво на извод за (z) трябва да има път от корена до листо с повече от (m) нетерминални върха. Причината е, че двоично дърво с височина най-много (m) има най-много (2^m) листа. Следователно, ако листата са поне (2^m), височината трябва да е по-голяма от (m).

Понеже по този път има повече от (m) нетерминални върха, а различните нетерминални символи са само (m), по принципа на Дирихле някой нетерминал се среща поне два пъти по пътя. Нека този нетерминал е (A). Разглеждаме две негови появи, като едната е по-високо в дървото, а другата е по-ниско. По-горната поява на (A) извежда някаква поддума (vwx), а по-долната поява на (A) извежда поддумата (w). Частта (v) е това, което се поражда отляво на по-долната поява на (A), а частта (x) е това, което се поражда отдясно на нея. Останалите части на думата са (u) и (y), така че цялата дума има вида

$$z = uvwxy.$$

От структурата на дървото следва, че има извод

$$A \Rightarrow^* vAx$$

и също така извод

$$A \Rightarrow^* w.$$

Затова можем вместо един път да приложим фрагмента (A^* vAx) произволен брой пъти. Ако го приложим нула пъти, получаваме (uwy). Ако го приложим два пъти, получаваме (uvvwxxy). В общия случай получаваме

$$uv^iwx^iy.$$

Понеже всяка така получена дума се поражда от същата граматика, тя принадлежи на (L).

Остава да се обяснят двете ограничения. Условието (|vx|>0) означава, че при разрастването действително се променя поне една част от думата. Ако и (v), и (x) бяха празни, повторението не би имало ефект. Условието (|vwx|p) се осигурява чрез избора на двете повторени появи на нетерминала достатъчно близо до листата. Така поддървото на по-горната поява има ограничена височина и следователно поражда дума с дължина най-много (p). Следователно са изпълнени всички условия на лемата.

Лемата за разрастването се използва за доказване, че езици не са контекстносвободни. Класически пример е езикът

$$L = a^n b^n c^n \mid n \geq 0.$$

Ще докажем, че този език не е контекстносвободен. Да допуснем противното, че (L) е контекстносвободен. Тогава по лемата за разрастването съществува константа (p). Избираме думата

$$z = a^p b^p c^p.$$

Тази дума принадлежи на (L) и има дължина поне (p). Следователно тя трябва да може да се представи като

$$z = uvwxy,$$

където (|vwx|p), (|vx|>0), и за всяко (i) думата ($uv^{iwx}iy$) също трябва да принадлежи на (L).

Понеже (|vwx|p), поддумата (vwx) не може да обхваща едновременно част от (a)-тата, част от (b)-тата и част от (c)-тата, защото между началото на блока от (a)-та и края на блока от (c)-та има повече от (p) символа. Следователно (vwx) се намира или изцяло в един от трите блока, или пресича границата между (a)-та и (b)-та, или пресича границата между (b)-та и (c)-та.

Ако (v) и (x) съдържат само символи от един и същ блок, тогава при разрастване ще се промени броят само на един вид символи. Например ще се увеличи или намали само броят на (a)-тата, или само на (b)-тата, или само на (c)-тата. Получената дума няма да има равен брой (a), (b) и (c), следователно няма да принадлежи на (L).

Ако (vwx) пресича границата между (a)-та и (b)-та, тогава (v) и (x) съдържат само (a)-та и (b)-та. При разрастване се променя броят на (a)-тата и/или (b)-тата, но броят на (c)-тата остава (p). Следователно равенството между трите броя се нарушава. Освен това при някои разраствания може да се наруши и блоковият ред, но дори без това е достатъчно, че броевете вече не са равни.

Аналогично, ако (vwx) пресича границата между (b)-та и (c)-та, при разрастване се променя броят на (b)-тата и/или (c)-тата, но броят на (a)-тата остава (p). Отново получената дума не може да бъде от вида (a^{nb}nc^n). Във всички възможни случаи съществува стойност на (i), например (i=0) или (i=2), за която (uv^{iwx}iyL). Това противоречи на лемата за разрастването. Следователно езикът ({a^{nb}nc^nn}) не е контекстносвободен.

Сега ще докажем, че класът на контекстносвободните езици не е затворен относно сечение. За целта трябва да намерим два контекстносвободни езика, чието сечение не е контекстносвободно. Нека

$$L_1 = a^i b^i c^j \mid i, j \geq 0$$

и

$$L_2 = a^i b^j c^j \mid i, j \geq 0.$$

Езикът (L_1) е контекстносвободен, защото може да се породи от граматика, която първо поражда равен брой (a)-та и (b)-та, а след това произволен брой (c)-та. Езикът (L_2) също е контекстносвободен, защото може да се породи от граматика, която първо поражда произволен брой (a)-та, а след това равен брой (b)-та и (c)-та.

Сечението на тези два езика е

$$L_1 \cap L_2 = a^n b^n c^n \mid n \geq 0.$$

Наистина, думите в (L_1) имат равен брой (a)-та и (b)-та, а думите в (L_2) имат равен брой (b)-та и (c)-та. Ако една дума принадлежи и на двата езика, тогава броят на (a)-тата е равен на броя на (b)-тата, а броят на (b)-тата е равен на броя на (c)-тата, следователно трите броя са равни. Получава се точно езикът ({a^nb^nc^nn}), който вече доказахме, че не е контекстносвободен. Следователно сечението на два контекстносвободни езика може да не е контекстносвободно, тоест класът на контекстносвободните езици не е затворен относно сечение.

Остава да докажем, че контекстносвободните езици не са затворени относно допълнение. Доказателството използва връзката между допълнение и сечение чрез законите на Де Морган. Да допуснем противното, че класът на контекстносвободните езици е затворен относно допълнение. Знаем, че контекстносвободните езици са затворени относно обединение. Тогава за всеки два контекстносвободни езика (A) и (B), техните допълнения () и () също биха били контекстносвободни. Понеже класът е затворен относно обединение, езикът

$$\bar{A} \cup \bar{B}$$

също би бил контекстносвободен. Ако отново използваме предполагаемата затвореност относно допълнение, тогава допълнението на този език също би било контекстносвободно. Но по закона на Де Морган:

$$\bar{\bar{A}} \cup \bar{\bar{B}} = A \cap B.$$

Следователно класът на контекстносвободните езици би бил затворен относно сечение. Това противоречи на вече доказаното, че не е затворен относно сечение. Следователно предположението е невярно и контекстносвободните езици не са затворени относно допълнение.

Обобщението на темата е следното. Контекстносвободните езици се пораждат от граматики, чиито правила заменят един нетерминал независимо от контекста. Изводите могат да се представят чрез дървета на извод, които разкриват структурата на думите. Този клас е затворен относно регулярните операции обединение, конкатенация и итерация на Клини. Лемата за разрастването дава необходимо условие за контекстносвободност и позволява да се доказва, че някои езици, като ({a^nb^nc^nn}), не са контекстносвободни. Накрая, чрез този език се доказва, че класът на контекстносвободните езици не е затворен относно сечение, а чрез законите на Де Морган се доказва и незатвореност относно допълнение.