24. Използване на XML за структуриране, валидация, обработка и представяне на документно съдържание

1. Добре-структуриран XML: Основни концепции и синтаксис

XML е език за маркиране, предназначен за създаване на структурирани документи, четими както от хора, така и от машини. Основната му цел е универсално съхранение и обмен на данни, независимо от платформата.

Основни компоненти

Всеки XML документ е изграден от следните градивни елементи:

- **Таг (Маркер):** Име на елемент, заградено в `<` и `>`.
- **Елемент:** Съвкупност от отварящ таг, съдържание и затварящ таг (напр. `<name>Ivan</name>`). Елементите могат да бъдат влагани, но винаги трябва да има точно един **коренов елемент** (root element).
- **Атрибут:** Допълнителна информация за елемента под формата на двойка `име="стойност"`, разположена в отварящия таг.
- **Метаданни:** Описание на семантиката на съдържанието.

XML йерархии

Структурата на XML се представя като йерархия (дърво), която може да бъде:

1. **Планарна:** Вертикално представяне на подредбата чрез влагане (nesting).
2. **Дървовидна:** Визуализира релациите „родител-дете“, където коренът е в основата, а листата са най-вложените елементи без под-елементи.

Синтактични правила

За да бъде един документ „добре-структуриран“ (well-formed), той трябва да спазва следните правила:

- **Чувствителност към регистъра:** `<Person>` и `<person>` са различни елементи.
- **Правилно затваряне:** Всеки отварящ таг задължително има съответстващ затварящ таг.
- **Без припокриване:** Елементите трябва да се затварят в реда, в който са отворени (аналогично на балансирани скоби).
- **Именуване:** Имената не могат да започват с „xml“ (в какъвто и да е регистър) или цифри. Могат да започват с буква или долна черта `_`.
- **Специални символи:** Символите `<`, `>`, `&`, `"` и `'` са резервирани и трябва да се заменят с техните entity референции (напр. `<` за `<`).

XML пространства от имена (Namespaces)

Използват се за избягване на колизии (конфликти) при еднакви имена на елементи от различни контексти. Дефинират се чрез атрибута `xmlns` и префикс, свързан с уникален URL адрес.

2. XML валидация чрез Document Type Definitions (DTD)

Валидацията проверява дали XML документът отговаря на предварително дефиниран речник и структура. DTD е традиционният механизъм за тази цел.

Цели и структура

DTD описва позволените елементи, техния ред и атрибути. То може да бъде **вътрешно** (inline в XML файла) или **външно** (в отделен `.dtd` файл).

Синтаксис и декларации

- **ELEMENT:** Дефинира модела на съдържание:
  - `EMPTY` – празен елемент.
  - `ANY` – произволно съдържание.
  - `#PCDATA` – текстово съдържание (Parsed Character Data).
  - **Индикатори за брой:** `+` (1 или повече), `*` (0 или повече), `?` (0 или 1).
- **ATTLIST:** Декларира атрибути за даден елемент. Типовете включват:
  - `CDATA` – обикновен текст.
  - `ID` – уникален ключ за елемента.
  - `IDREFS` – списък от референции към други ID-та.
  - **Декларация на стойност:** `#REQUIRED` (задължителен), `#IMPLIED` (опционален), `#FIXED` (фиксиран).
- **ENTITY:** Използва се като указател към текст или външен ресурс (напр. изображение).
- **NOTATION:** Специфицира типа на не-XML данни (напр. `image/jpeg`).

3. XML валидация чрез XML Schema (XSD)

XML Schema е по-мощен наследник на DTD, който сам по себе си е XML документ.

Спецификации и типове данни

За разлика от DTD, XML Schema поддържа богата палитра от типове данни (integer, date, boolean, string и др.). Тя разделя компонентите на:

- **SimpleType:** Елементи, които съдържат само текст и нямат атрибути или под-елементи.
- **ComplexType:** Елементи, които могат да съдържат под-елементи и атрибути.

Модели на групиране

- `<xs:sequence>`: Елементите трябва да се появят в точно указания ред.
- `<xs:all>`: Елементите могат да са във всеки ред, но трябва да присъстват.
- `<xs:choice>`: Позволява избор само на един елемент от списъка.

Фасети (Facets)

Фасетите са ограничения върху пространството от стойности на даден тип.

- **Ограничаващи:** `minInclusive/maxInclusive`, `length`, `pattern` (регулярни изрази), `enumeration` (изброяване).

Сравнение между DTD и XML Schema

Характеристика	DTD	XML Schema (XSD)
Синтаксис	Специфичен (не е XML)	XML синтаксис
Типове данни	Не поддържа (само текст)	Поддържа вградени и потребителски типове
Пространства от имена	Ограничена поддръжка	Пълна поддръжка
Мощност	Базова структура	Висока (фасети, наследяване)

4. XSLT и XPath: Трансформация и навигация

XPath (XML Path Language)

XPath служи за адресиране и извличане на части от XML документ, представяйки го като дърво от възли (корен, елемент, атрибут, текст).

- **Синтаксис:** Подобен на файлова система (`/` за корен, `//` за избор навсякъде).
- **Оси (Axes):** `child`, `parent`, `ancestor`, `descendant`, `attribute` (`@`).
- **Контекстен възел:** Отбелязва се с точка `.` (текущото местоположение на процесора).

XSLT (eXtensible StyleSheet Language Transformations)

XSLT се използва за трансформиране на XML в други формати (HTML, обикновен текст или друг XML).

- **Шаблони:** Използва се `<xsl:template match="...">` за дефиниране на правила за обработка.
- **Елементи за контрол:** `<xsl:for-each>` (цикъл), `<xsl:value-of>` (извличане на стойност), `<xsl:if>` (условие), `<xsl:variable>` (дефиниране на променливи).

5. Обработка на XML документи: DOM и SAX

За програмна работа с XML се използват два основни модела (API).

DOM (Document Object Model)

DOM зарежда целия XML документ в паметта като йерархична структура от обекти (`Node`).

- **Предимства:** Позволява произволен достъп, лесна навигация в двете посоки и модификация (добавяне/изтриване на елементи).
- **Недостатъци:** Консумира много памет при големи документи.
- **Основни интерфейси:** `Node`, `Document`, `Element`, `Attr`, `Text`.

SAX (Simple API for XML)

SAX е събитийно-ориентиран (event-driven) модел, който чете документа последователно (push модел).

- **Механизъм:** Парсерът генерира събития (напр. "старт на елемент", "текст"), които се обработват от манипулатори (`handlers`).
- **Предимства:** Много ниска консумация на памет; бърз при четене на огромни файлове.
- **Недостатъци:** Само четене (без модификация), навигация само напред.
- **Основни интерфейси:** `ContentHandler`, `XMLReader`, `ErrorHandler`.

Речник на ключовите термини

- **#PCDATA (Parsed Character Data):** Текстово съдържание в XML, което ще бъде анализирано от парсера.
- **CDATA (Character Data):** Област от данни, която парсерът не интерпретира (използва се за код или текст със специални символи).
- **Entity (Единица):** Променлива, използвана за заместване на повтарящ се текст или външни ресурси.
- **Facet (Фасет):** Ограничение в XML Schema, дефиниращо допустимите стойности за даден тип (напр. дължина).
- **Namespace (Пространство от имена):** Механизъм за уникално идентифициране на таговете чрез URI, предотвратяващ конфликти на имена.
- **Node (Възел):** Основна единица в дървовидната структура на DOM или XPath.
- **Root Element (Коренов елемент):** Най-външният елемент в XML документа, който съдържа всички останали.
- **XSD (XML Schema Definition):** Документ, дефиниращ структурата, съдържанието и ограниченията на XML инстанциите.
- **XSLT Template:** Правило в XSLT, което казва на процесора какво да прави при намиране на съвпадение с определен XPath път.